

AWI-ESM3-4-2-veg-HR, CMIP7 piControl

Stand nach cli119: latitude/longitude, und #81 auf dem ganzen Jahr

Jan Streffing, AWI

13. September 2026

1 Kurzfassung

Danke fuer den Lauf mit den Koordinatenchecks auf cli118. Der eine Befund, die Namen der Hilfskoordinaten, ist behoben. cli119 ist das Jahr 1851 mit 529 Dateien, geschrieben mit dieser Korrektur. Wir haben es komplett mit deinem #81 in 5a4239e geprueft, also dem Stand nach deinem Lauf:

HIGH	cli118, dein Lauf	cli119 mit #81
wcrp_cmip7 COORD011, Namen der Hilfskoordinaten	455 Dateien	0
wcrp_cmip7 TIME001	0	0
aicc vegtype auf landCoverFrac	1	1
cf Appendix A, formula_terms auf lev_bnds	9	9

wcrp_cmip7 meldet damit auf dem ganzen Jahr kein HIGH mehr. Was bleibt, liegt in der Tabelle und im cf-Checker, nicht in den Dateien.

Dazu ein Fehler bei uns, den kein Checker sehen konnte: die dekadischen Dateien enthielten bis einschliesslich cli119 nur ein Jahr. Das ist behoben, Abschnitt 4, mit zwei Fragen an dich.

2 latitude und longitude

Zwei Tabellen benennen die horizontalen Koordinaten. CMIP7_coordinate.json gilt fuer die Achsen regulaerer Gitter, out_name lat/lon. Darauf hatten wir in der dritten Runde 41 Dateien von latitude(latitude) auf lat(lat) umgestellt. CMIP7_grids.json gilt fuer die Gittervariablen kurvilinearer und unstrukturierter Gitter, out_name latitude/longitude. Dort hatten unsere Hilfskoordinaten einfach den Namen behalten, den XIOS oder das Mesh mitbrachte. Keiner der bisherigen Checker hat darauf geschaut.

Hilfskoordinaten heissen jetzt latitude/longitude, und jedes coordinates-Attribut zieht mit. Regulaere Gitter behalten lat(lat) und lon(lon), die Umstellung aus Runde drei gilt also weiter.

Gitter	Dateien	in cli119
g122	321	latitude(ncells) bzw. latitude(cell)
g130	125	latitude(ncells)
g132	9	latitude(elem)
g129, g239	45	lat(lat), unveraendert
g010	29	ohne horizontale Koordinaten

g132 stand nicht in deiner Liste, war aber genauso betroffen, die neun Dateien sind mit umgestellt.

3 TIME001

In deinem Lauf auf cli118 war TIME001 schon verschwunden. Seitdem hat #81 die Pruefung noch einmal umgebaut, die Intervallgrenzen werden jetzt aus dem Dateinamen neu erzeugt statt den deklarierten Grenzen zu vertrauen. Genau unsere 42 subdaily- und dekadischen Dateien haengen daran, deshalb wollten wir das nachmessen. Auch mit 5a4239e bleiben alle 42 ohne Befund.

Auf cc-plugin-wcrp#80 hat Ayoubnac1 geschrieben, dass mehrere Dekaden in einer Datei unter proleptic_gregorian noch um zwei Stunden daneben liegen. Das betrifft uns nicht, jede unserer dec-Dateien umfasst genau eine Dekade. Was in dieser Dekade stand, war allerdings falsch, dazu der naechste Abschnitt.

4 Dekadenmittel: ein Fehler bei uns

Wir cmorisieren jahresweise, ein Modelljahr pro Job, und jedes Eingabemuster wird auf dieses Jahr gepinnt. Das galt auch fuer die neun dec-Variablen (thetao, so, tauuo, tauvo, thkcello, volo, masscello, volcello, masso). Die Grenzen haben wir korrekt als 1850 bis 1860 geschrieben, gemittelt wurde aber nur das jeweils verarbeitete Jahr. Jedes weitere Jahr derselben Dekade haette dieselbe Datei mit einem anderen Einjahresmittel ueberschrieben. Strukturell sind diese Dateien in Ordnung, deshalb ist es in keiner QC aufgefallen. Die neun dec-Dateien aus cli117 bis cli119 sind nicht zu verwenden.

Jetzt. Jeder Jahresjob traegt die dec-Regeln weiter mit. Ein erster Schritt zaehlt das Startjahr des Laufs jedes Mal neu aus den Eingabedateien und zaehlt Dekaden ab diesem Jahr. Die Regel schreibt nur in dem Jahr, das eine Dekade schliesst, und liest dann alle zehn Jahre; in jedem anderen Jahr endet sie ohne Ausgabe. Fehlt in einer schliessenden Dekade ein Jahr, ist das ein Fehler, kein Uebergehen. Eine unvollstaendige letzte Dekade wird nicht geschrieben.

Nachgemessen fuer 1858 und 1859:

- 1858: alle neun Regeln enden ohne Ausgabe.
- 1859: neun Dateien, time 1855-01-01, Grenzen 1850-01-01 bis 1860-01-01, jeweils zehn Eingabedateien gelesen.
- tauuo an 2000 zufaelligen Zellen gegen das Mittel der 120 Monatswerte: Abweichung 10^{-5} , also float32-Genauigkeit. Gegen 1859 allein: 115 %.
- #81 in 5a4239e: kein HIGH auf den neun Dateien.

Warum ab Laufbeginn und nicht nach Kalenderdekaden. Weder die CV (dec: „Decadal samples“, Intervall zehn Jahre) noch die CMIP7-Guidance legen fest, wo eine Dekade beginnt. #81 ist es ebenfalls egal, solange die Zelle zehn Jahre lang ist: 1850–1860, 1851–1861 und 2024–2034 bestehen, 2024–2030 und 2040–2046 werden als HIGH gemeldet („does not match regular 10-year cells“). In /pool/data/CMIP6 ist es uneinheitlich: AWI-CM-1-1-MR und AWI-ESM-1-1-LR zaehlen 1851–1860 und lassen angebrochene Dekaden weg, IPSL-CM6A-LR nimmt fuer historical 1850–1859, fuer ssp585 aber Dekaden ab 2015, MIROC6 hat eine Zelle 2010–2014 veroeffentlicht.

Zwei Fragen dazu:

1. Ist es fuer euch in Ordnung, dass eine angebrochene letzte Dekade fehlt, im piControl also 2040–2045, statt als kuerzere Zelle zu erscheinen?
2. Sollen Szenarien ihre Dekaden ab Experimentbeginn zaehlen, bei einem Start 2024 also 2024–2033, oder nach Kalenderdekaden ab 2030? Ab Beginn geht nichts verloren, nach Kalender liegen historical und Szenario auf demselben Raster.

5 Was uebrig bleibt

Anzahl	Befund	liegt bei
1 HIGH	vegtype, Singular needleleaf_evergreen_tree	CMIP7_DReq_Content#29
9 HIGH	cf Appendix A gegen CF 1.7 §7.1, formula_terms	compliance-checker
492 MEDIUM	„Registry has no value for key 'cell_measures'“	WCRP-universe#334

Eine Korrektur zur fuenften Antwort. Dort stand, dass die 492 MEDIUM mit #81 vermutlich verschwinden, weil der PR die Kompatibilitaet von `units` und `cf_units` behandelt. Das stimmt nicht: mit 5a4239e sind es weiterhin 492. Die Universe-Datenbank 3.2.0 fuehrt fuer `known_branded_variable` schlicht kein `cell_measures`, und das kann der Checker nicht ausgleichen. Laut WCRP-universe#334 kommt die Korrektur mit dem QA/QC-Release fuer die Koordinatenchecks.

Ein MEDIUM mehr als ohne #81 gibt es auf den beiden `time4`-Dateien: #81 meldet den Tippfehler `Satistics` aus der Tabelle, der schon in deinem `CMIP7_DReq_Content#31` steht.

6 Zu deinen weiteren Punkten

Zum Gitterregister: solange `grid_type` nicht aus EMD in die CV kommt, behalten wir unser eigenes Register fuer `aicc`. Wenn #81 ueber `grid_label` auf die Topologie kommt, pruefen wir, ob unsere Labels dort hinterlegt sind. `g239` ist inzwischen auch auf `main` von CMIP7-CVs angekommen.

Die Konsistenzbefunde zwischen Datensaeetzen aus `esgf-qa` lassen wir liegen, bis du die Gruppen neu gebildet hast.

7 Wie gemessen wurde

Die QC im Lauf selbst ist gegenueber `cli118` unveraendert: cf 0 HIGH, 128 MEDIUM, `wcrp_cmip7_develop` ba2de16 42 HIGH und 613 MEDIUM, `aicc` 1 HIGH. Die Umbenennung kostet also mit den heute veroeffentlichten Checkern nichts.

Da keine der QC-Suiten die Werte selbst prueft, laeuft bei uns zusaetzlich ein Abgleich jeder Datei mit Literaturbereichen fuer Minimum, Mittel und Maximum. Auf `cli119` bestehen 307 von 529 Dateien, 169 liegen knapp ausserhalb, 53 deutlich. 49 der 53 fielen schon im August auf, die Ursachen gehen wir gerade durch.

Die Pruefung mit #81 lief danach separat ueber alle 529 Dateien, mit dem PR-Stand 5a4239e in einem eigenen Checkout, `compliance-checker` 6.1.0 mit aktivierten Appendix-A-Checks, `cc-plugin-aicc` 0.2.0 mit unserem Register, `esgvc` 6.1.0 mit `cmip7@2.3.0` und `universe@3.2.0`. Die Dateien liegen unter `/scratch/a/a270092/pycmor_hr/cli119/cmorized/MIP-DRS7`, die Reports aus der Pruefung mit #81 unter `/scratch/a/a270092/pycmor_hr/cli119_pr81`.